

Министерство науки и высшего образования Российской Федерации  
«Московский физико-технический институт (государственный университет)»

Физтех-школа прикладной математики и информатики

Факультет управления и прикладной математики

Кафедра «Интеллектуальные системы»

Бухонов Сергей Александрович

**Мультимодальное селективное комбинирование классификаторов для  
выделения полезного сигнала на энцефалограмме при быстром  
поточном предъявлении визуальных раздражителей**

03.04.01 — Прикладные математика и физика

Выпускная квалификационная работа (магистерская диссертация)

Научный руководитель: д. т. н.

Моттль Вадим Вячеславович

Москва 2019

## **Аннотация**

Работа посвящена классификации снимков маммограмм по реакции ЭЭГ экспертов-маммологов, которым визуально предъявляются данные снимки с большой частотой. За основу взят метод опорных векторов, были исследованы модификации данного метода. Проанализирована работа метода опорных векторов с учетом требования гладкости решающего правила, с учетом критерия селективности. Получены результаты работы по каждому отдельному варианту модификации метода опорных векторов, а также результаты работы комбинированного классификатора, основанного на классическом методе опорных векторов и его модификациях.

## Оглавление

Введение .....	4
1. Анализ предметной области и постановка задачи.....	7
1.1 Использование энцефалографии в научных целях.....	7
1.2 Постановка задачи.....	9
2. Алгоритм двухклассовой классификации сигналов ЭЭГ.....	10
2.1 Классическая постановка задачи классификации .....	10
2.2. SVM с требованием гладкости решающего правила.....	11
2.3. SVM с регулируемой селективностью.....	12
2.4 Построение комбинированного классификатора .....	14
3. Вычислительный эксперимент.....	15
Заключение.....	18
Список литературы .....	19

## **Введение**

Нейрокомпьютерный интерфейс (НКИ) – система, созданная для взаимодействия мозга с электронным устройством [1].

Начало построения НКИ относится к 1924 году, когда немецкий физик и психиатр Ханс Бергер исследовал электрическую активность головного мозга и впервые получил ее запись – электроэнцефалограмму (ЭЭГ). Во второй половине XX века проводились исследования, в рамках которых регистрировалась мозговая активность животных. В исследованиях по изучению мозговой активности человека одно из первых отмечают в 60-е годы в университете Беркли в Калифорнии, основанное на анализе ЭЭГ для декодирования простой бинарной команды.

Для систем НКИ могут использоваться различные сигналы, отражающие мозговую активность: ЭЭГ, магнитоэнцефалограмма, электрокортикограмма, импульсная активность нейронов, интенсивность кровотока в мозге. Однако в большинстве исследований в качестве сигналов используются электрические. Электроэнцефалография – метод записи электрической активности головного мозга, регистрируемой с поверхности кожи головы.

Использование ЭЭГ в ходе нейробиологических исследований имеет целый ряд преимуществ перед другими инструментальными методами. Во-первых, ЭЭГ представляет собой неинвазивный способ исследования объекта. Во-вторых, нет такой жесткой необходимости оставаться в неподвижном состоянии, как при проведении функциональной МРТ. В третьих, в ходе ЭЭГ регистрируется спонтанная активность мозга, поэтому от субъекта не требуется взаимодействия с исследователем (как, например, это требуется в поведенческом тестировании в рамках психологического исследования). Кроме того, ЭЭГ обладает высоким разрешением во времени по сравнению с такими методами, как функциональная МРТ, и может использоваться для идентификации миллисекундных колебаний электрической активности мозга.

Основные операции и последовательность обработки сигналов в нейрокомпьютерном интерфейсе, представлены на рисунке 1.

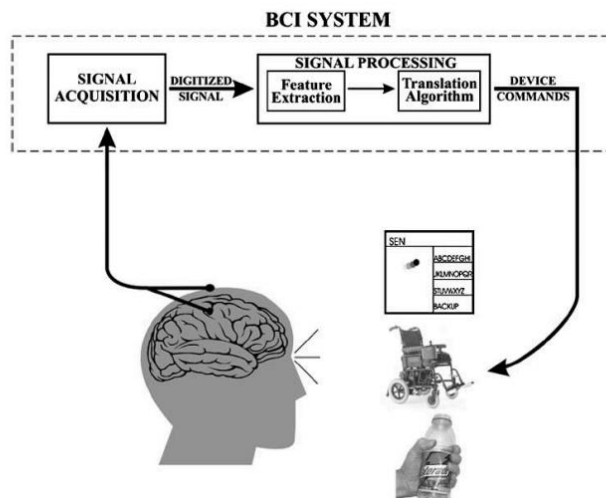


Рисунок 1 – Общий принцип построения НКИ

Методология RSVP (Rapid serial visual presentation – быстрое последовательное визуальное предъявление) реализует принцип интегрального восприятия большого количества визуальных данных, минуя этап осознанного принятия решений. Это обеспечивается передовой вычислительной мощностью визуальной системы человека, которая, как было установлено, способна идентифицировать и классифицировать содержимое изображения как целевое или нецелевое с частотой более 10 Гц [2].

В совместном исследовании Департамента психологии и Центра обработки речи, изображений и сигналов (отдел электронной инженерии) в Университете Суррея был изучен НКИ с RSVP-подходом для потенциального использования RSVP в медицинской области в качестве метода скрининга (проведения определенных обследований и тестов, направленное на выявления возможных онкологических заболеваний) [2].

Информация, полученная в ходе маммографического скрининга, использовалась в качестве стимулов, а испытуемые были специалистами в области маммографии. Набор стимулов состоял из небольшого количества сегментов маммограмм, содержащих изображение молочной железы со злокачественной опухолью (целевые) и большого количества сегментов маммограмм здоровой молочной железы (нецелевые).

На рисунке 1 проиллюстрированы целевые и нецелевые стимулы.




Рисунок 1 – Целевые и нецелевые стимулы

Применяя методологию RSVP, изображения были представлены испытуемым со скоростью 10 изображений в секунду. В экспериментах наблюдалось, что вызванные потенциалы, соответствующие целевым изображениям, могут быть отличны от потенциалов, соответствующих нецелевым изображениям.

Целью данной работы является улучшение качества классификации сигналов энцефалограммы головного мозга путем применения метода опорных векторов (SVM). В ходе данной работы были проанализированы три реализации SVM: классический, с требованием гладкости решающего правила, и с критерием селективности.

## 1. Анализ предметной области и постановка задачи

### 1.1 Использование энцефалографии в научных целях

При определении сигнала энцефалограммы как реакции на целевой стимул в сигнале проверяют наличие определенного компонента – P300.




Рисунок 2 – Компонент P300 в сигнале ЭЭГ как реакция на целевой стимул

Такой подход применим совместно с методологией RSVP. В работе [3] была предложена система на основе обработки ЭЭГ с применением RSVP для просмотра и идентификации в режиме реального времени изображений. В качестве одного из проведенных экспериментов можно привести определение спутниковых снимков, на которых изображены позиции зенитных управляемых ракет.


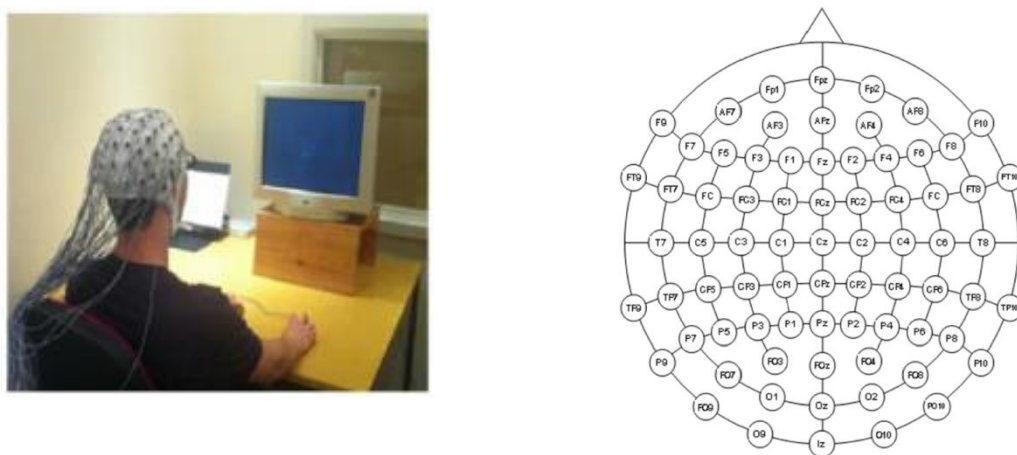


Рисунок 3 – Снимки с изображением целевых объектов (обведены зеленым) и нецелевые.

В работе [4] исследовалась реакция испытуемых на предъявленные изображения, на которых были представлены люди разной степени


знакомства. Результатом являлось выявление определенного компонента FN400 (отрицательное отклонение между 300-500 мс), появление которого определялось как узнавание человека на соответствующем предъявленном изображении.

В работе [5] практическая задача заключалась в определении патологий на снимках маммограмм, анализируя реакцию эксперта-маммолога на предъявляемые снимки. На рисунке 4а и 4б показан процесс снятия ЭЭГ в процессе просмотра изображений и схема расположения электродов соответственно.



**Рисунок 4.а) – Процесс снятия ЭЭГ , б) – Схема расположения электродов**

На рисунке 5 представлены сигналы энцефалограммы, записанные с электродов, соответствующие одному стимулу.



**Рисунок 5 – Сигнал ЭЭГ**



В эксперименте участвовало 4 специалиста-маммолога. Классификации сигналов был использован линейный дискриминант Фишера. В таблице 1 представлены результаты классификации.

Специалист	AUC
1	0.84
2	0.71
3	0.82
4	0.86

Таблица 1 – Результаты экспериментов с применением линейного дискриминанта Фишера

## 1.2 Постановка задачи

Поскольку просмотр экспертом целевых (с патологией) и нецелевых (без патологий) изображений маммограмм обычно приводит к разной мозговой активности, классификация зарегистрированных ЭЭГ-сигналов в данном случае заключается в обнаружении того, содержит ли некоторый фрагмент ЭЭГ отклик на целевое изображение или нет. С математической точки зрения такая задача является двухклассовой задачей распознавания образов.

Рассматриваемые объекты представляют собой записи сигналов ЭЭГ эксперта в области маммологии, зарегистрированные с 66 электродов. Каждому представленному изображению соответствует фрагмент ЭЭГ длиной 1100 отсчетов по каждому электроду.

$$(\mathbf{X}_i, \mathbf{y}_i), i = 1, \dots, N$$

Требуется построить алгоритм  $\mathbf{a}: \mathbf{X} \rightarrow \mathbf{Y}$ , способный классифицировать объект  $\mathbf{x} \in \mathbf{X}$

## 2. Алгоритм двухклассовой классификации сигналов ЭЭГ

### 2.1 Классическая постановка задачи классификации

Для решения задачи классификации сигналов энцефалограммы был выбран SVM. Задача построения модели классификации сводится к нахождению коэффициентов разделяющей гиперплоскости, наилучшим образом разделяющей два класса.

$$\begin{cases} \sum_{i=1}^m a_i^2 + C \sum_{j=1}^N \delta_j \rightarrow \min(\mathbf{a}, b, \boldsymbol{\delta}), \\ y_j (\sum_{i=1}^m a_i x_{ij} - b) \geq 1 - \delta_j, \quad j = 1, \dots, N, \\ \delta_j \geq 0, \quad j = 1, \dots, N, \end{cases} \quad (1)$$

Где  $\mathbf{a} = [a_1, \dots, a_n]$  – направляющий вектор гиперплоскости,  $b$  – смещение гиперплоскости вдоль направляющего вектора,  $\delta_j$  – величина ошибки на  $j$ -ом объекте,  $C$  – настраиваемый параметр, определяющий степень влияния ошибок.

Данная задача сводится к решению двойственной задачи квадратичного программирования

$$\begin{cases} W(\lambda_1, \dots, \lambda_N) = \sum_{j=1}^N \lambda_j - \frac{1}{2} \sum_{j=1}^N \sum_{k=1}^N (y_j y_k \mathbf{x}_j^T \mathbf{x}_k) \lambda_j \lambda_k \rightarrow \max(\lambda), \\ \sum_{j=1}^N \lambda_j y_j = 0, \quad 0 \leq \lambda_j \leq C, \quad j = 1, \dots, N. \end{cases} \quad (2)$$

где  $\lambda_j$  – множители Лагранжа. Параметры гиперплоскости выражаются следующим образом:

$$\mathbf{a} = \sum_{j=1}^N \lambda_j y_j \mathbf{x}_j$$

$$b = \sum_{i=1}^m a_i x_{ij} - y_j, \text{ при } \lambda_j > 0$$

## 2.2. SVM с требованием гладкости решающего правила

В предположении, что отдельные признаки объекта в составе вектора  $\mathbf{x}$  представляют собой результат упорядоченного изменения одного из свойств и что соседние признаки несут практически идентичную информацию о принадлежности объекта к тому или иному классу, разумно в процессе обучения отдавать предпочтения решающим правилам с плавным изменением коэффициентов линейной части. Для этого вводим дополнительную аддитивную составляющую

$$\begin{cases} \sum_{i=1}^m a_i^2 + \gamma \sum_{i=2}^m (a_i - a_{i-1})^2 + C \sum_{j=1}^N \delta_j \rightarrow \min(\mathbf{a}, \mathbf{b}, \boldsymbol{\delta}), \\ y_j (\sum_{i=1}^m a_i x_{ij} - b) \geq 1 - \delta_j, \quad j = 1, \dots, N, \\ \delta_j \geq 0, \quad j = 1, \dots, N, \end{cases} \quad (3)$$

где  $\gamma$  – коэффициент гладкости решающего правила. Данный метод регуляризации был предложен в [6]. Аддитивная составляющая

$$J'(\mathbf{a}) = \sum_{i=2}^n (a_i - a_{i-1})^2$$

Может быть представлена в виде  $J'(\mathbf{a}) = \mathbf{a}^T \tilde{\mathbf{B}} \mathbf{a}$ , где

$$\tilde{\mathbf{B}}(n \times n) = \begin{pmatrix} 1 & -1 & 0 & \dots & 0 & 0 & 0 \\ -1 & 2 & -1 & \dots & 0 & 0 & 0 \\ 0 & -1 & 2 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 2 & -1 & 0 \\ 0 & 0 & 0 & \dots & -1 & 2 & -1 \\ 0 & 0 & 0 & \dots & 0 & -1 & 1 \end{pmatrix}.$$

Следовательно, целевая функция в задаче (3) примет вид

$$\frac{1}{2} (\mathbf{a}^T \mathbf{a} + \gamma \mathbf{a}^T \tilde{\mathbf{B}} \mathbf{a} + C \sum_{j=1}^N \delta_j) \rightarrow \min(\mathbf{a}, \mathbf{b}, \boldsymbol{\delta}),$$

или более компактно  $\frac{1}{2} \mathbf{a}^T \mathbf{B} \mathbf{a} + C \sum_{j=1}^N \delta_j \rightarrow \min(\mathbf{a}, b, \delta)$ , где  $\mathbf{B} = \mathbf{I} + \gamma \tilde{\mathbf{B}}$

Задача (3) сводится к решению двойственной задачи

$$\begin{cases} W(\lambda_1, \dots, \lambda_N) = \sum_{j=1}^N \lambda_j - \frac{1}{2} \sum_{j=1}^N \sum_{k=1}^N (y_j y_k \mathbf{x}_j^T (\mathbf{I} + \gamma \tilde{\mathbf{B}})^{-1} \mathbf{x}_k) \lambda_j \lambda_k \rightarrow \max(\lambda), \\ \sum_{j=1}^N \lambda_j y_j = 0, \quad 0 \leq \lambda_j \leq C, \quad j = 1, \dots, N. \end{cases}$$

Направляющий вектор гиперплоскости в данном случае будет выражаться следующим образом:

$$\mathbf{a} = (\mathbf{I} + \gamma \tilde{\mathbf{B}})^{-1} \sum_{j=1}^N \lambda_j y_j \mathbf{x}_j$$

### 2.3. SVM с регулируемой селективностью

Чем больше электродов, тем больше размер признакового пространства объекта. Это может привести к проблеме переобучения. Также, не со всех электродов может поступать полезная информация, помогающая в принятии решения. Следовательно, необходим инструмент, который позволит автоматически отбирать электроды, сигналы с которых являются наиболее информативными.

Оптимизационная задача после введения данного типа регуляризации выглядит следующим образом [3]

$$\begin{cases} J(a_1, \dots, a_m, b, \delta_1, \dots, \delta_N, C, \mu) = \sum_{i=1}^m q(a_i | \mu) + C \sum_{j=1}^N \delta_j \rightarrow \min(\mathbf{a}, b, \delta), \\ q(a_i | \mu) = \begin{cases} 2\mu |a_i| & \text{if } |a_i| \leq \mu, \\ \mu^2 + a_i^2 & \text{if } |a_i| > \mu, \end{cases} \\ y_j \mathbf{a}^T \mathbf{x}_j + b \geq 1 - \delta_j, \quad \delta_j \geq 0, \quad j = 1, \dots, N. \end{cases} \quad (4)$$

Решение данной оптимизационной задачи эквивалентно решению двойственной задачи

$$\left\{ \begin{array}{l} L \lambda_1, \dots, \lambda_N \mid C, \mu = \sum_{j=1}^N \lambda_j - \sum_{i \in I} \frac{\xi_i}{2} \rightarrow \max(\lambda_1, \dots, \lambda_N), \\ \xi_i \geq 0, \quad \xi_i \geq \sum_{j=1}^N \sum_{l=1}^N y_j y_l x_{ij} x_{il} \lambda_j \lambda_l - \mu^2, \quad i \in I = \{1, \dots, m\}, \\ \sum_{j=1}^N y_j \lambda_j = 0, \quad 0 \leq \lambda_j \leq \frac{C}{2}, \quad j = 1, \dots, N, \end{array} \right.$$

Которая может быть выражена в виде

$$\left\{ \begin{array}{l} \hat{a}_i = \sum_{j: \hat{\lambda}_j > 0} y_j \hat{\lambda}_j x_i(\omega_j), \\ i \in I^+ = i \in I: \sum_{j=1}^N \sum_{l=1}^N y_j y_l x_{ij} x_{il} \hat{\lambda}_j \hat{\lambda}_l > \mu^2, \\ \hat{a}_i = \hat{\eta}_i \sum_{j: \hat{\lambda}_j > 0} y_j \hat{\lambda}_j x_i(\omega_j), \\ i \in I^0 = i \in I: \sum_{j=1}^N \sum_{l=1}^N y_j y_l x_{ij} x_{il} \hat{\lambda}_j \hat{\lambda}_l = \mu^2, \\ \hat{a}_i = 0, \quad i \in I^- = i \in I: \sum_{j=1}^N \sum_{l=1}^N y_j y_l x_{ij} x_{il} \hat{\lambda}_j \hat{\lambda}_l < \mu^2, \end{array} \right.$$

Таким образом, оптимальная гиперплоскость может быть выражена в виде:

$$\sum_{j: \lambda_j > 0} y_j \lambda_j \sum_{i \in I^+} x_{ij} x_i + \sum_{i \in I^0} \eta_i x_{ij} x_i + b \geq 0,$$

где числовые параметры  $\{0 \leq \eta_i \leq 1, i \in I^0; b\}$  определяются решением задачи линейного программирования:

$$\begin{cases} 2\mu^2 \sum_{i \in I^0} \eta_i + C \sum_{l=1}^N \delta_j \rightarrow \min(\eta_i, i \in I^0; b; \delta_1, \dots, \delta_N), \\ \sum_{i \in I^0} \left( \sum_{l=1}^N y_j y_l x_{ij} x_{il} \lambda_l \right) \eta_i + y_j b + \delta_j \geq 1 - \sum_{i \in I^+} \left( \sum_{l=1}^N y_j y_l x_{ij} x_{il} \lambda_l \right), \\ \delta_j \geq 0, \quad j = 1, \dots, N, \quad 0 \leq \eta_i \leq 1, \quad i \in I^0. \end{cases}$$

## 2.4 Построение комбинированного классификатора

В случае решении сложных задач классификации возможна ситуация, когда ни один из алгоритмов не дает необходимого качества. При возникновении подобных ситуаций целесообразно воспользоваться комбинированным классификатором.

В общем случае комбинированный классификатор имеет вид

$$a(x) = C(F(b_1(x), \dots, b_n(x)))$$

где  $x \in X$  – объект,  $F$  – корректирующая операция,  $C$  – решающее правило. В качестве корректирующей операции используют, например, голосование по большинству или взвешенное голосование.

После построения моделей классификаторов их необходимо проверить на качество классификации. В таком случае разумно построить комбинированный классификатор, состоящий из композиции классификаторов. Один из способов построения комбинированного классификатора является голосование по большинству.

Данный способ заключается в присваивании объекту такой метки класса, предпочтение которой отдали наибольшее количество классификаторов. В качестве классификаторов примем описанные ранее классический SVM, SVM с требованием гладкости решающего правила и SVM с селективным отбором признаков.

Общий вид комбинированного классификатора для двухклассового распознавания с голосованием по большинству

$$y = a(x) = \text{sign} \left( \sum_{i=1}^n a_i(x) \right)$$

где  $a_i(x)$  – ответ  $i$ -ого алгоритма на поданный на вход объект  $x$ .

Таким образом, снимок маммограммы относится к тому из двух классов, к которому реакцию эксперта на него, записанную при помощи ЭЭГ, отнесло большинство классификаторов

### **3. Вычислительный эксперимент**

В первую очередь в ходе экспериментального исследования было проведено обучение распознаванию для каждого электрода в отдельности со сглаживанием и без сглаживания, а также с учетом требования гладкости решающего правила и без учета данного требования.

Качество построенных решающих правил оценивалось значением площади под ROC-кривой (AUC), построенной по тестовой совокупности. При применении регуляризации первого типа, предъявляющей требование гладкости решающего правила, выбор коэффициента гладкости.

Для каждого электрода осуществлялся автоматически по результатам скользящего контроля на обучающей совокупности. Полученные результаты приведены в таблице 2.

Сглаживание						Сглаживание					
-						-					
+						+					
Требование						Требование					
гладкости						гладкости					
-						-					
+						+					
Номер электрода	1	0,6858	0,6855	0,657	<b>0,6985</b>	34	0,5012	<b>0,5036</b>	0,4781	0,4944	
	2	0,6431	0,6192	0,6009	<b>0,6611</b>	35	0,5012	<b>0,576</b>	0,5493	0,5558	
	3	0,6644	0,6758	0,6308	<b>0,6901</b>	36	0,6348	0,6711	0,63	<b>0,6985</b>	
	4	0,6683	0,6473	0,6411	<b>0,689</b>	37	0,7203	0,8257	0,7364	<b>0,8451</b>	
	5	<b>0,6582</b>	0,6174	0,6124	0,6167	38	0,6085	0,696	0,6259	<b>0,6997</b>	
	6	0,6425	0,6791	0,6292	<b>0,6806</b>	39	0,7062	0,6931	0,6811	<b>0,7431</b>	
	7	<b>0,6091</b>	0,5954	0,5827	0,5816	40	<b>0,5897</b>	0,5857	0,5464	0,547	
	8	0,6766	0,6778	0,6242	<b>0,6873</b>	41	0,6088	0,655	0,6291	<b>0,6742</b>	
	9	0,5714	0,6161	0,5782	<b>0,6267</b>	42	0,7708	0,8584	0,7815	<b>0,8672</b>	
	10	<b>0,6053</b>	0,555	0,5384	0,5746	43	<b>0,5378</b>	0,5366	0,5268	0,5518	
	11	0,5509	0,5613	0,5724	<b>0,576</b>	44	0,545	0,5642	0,5664	<b>0,5735</b>	
	12	<b>0,5929</b>	0,5478	0,5504	0,5593	45	0,5924	0,6715	0,6281	<b>0,6961</b>	
	13	0,5368	0,5254	0,5541	<b>0,5589</b>	46	0,6428	0,7447	0,6951	<b>0,7671</b>	
	14	0,5295	<b>0,5405</b>	0,5226	0,5397	47	0,5491	<b>0,6056</b>	0,5669	0,5759	
	15	0,5595	0,6175	0,5876	<b>0,5891</b>	48	0,5628	<b>0,6101</b>	0,5775	0,5869	
	16	<b>0,5191</b>	0,5157	0,5171	0,5119	49	0,5713	<b>0,5866</b>	0,5371	0,5455	
	17	0,5756	0,5609	0,563	<b>0,5891</b>	50	0,4918	<b>0,5419</b>	0,5268	0,5388	
	18	0,5844	0,5601	0,5798	<b>0,6629</b>	51	0,5852	<b>0,603</b>	0,575	0,6005	
	19	0,6222	0,5994	0,5969	<b>0,6692</b>	52	0,5622	0,5515	0,5829	<b>0,5787</b>	
	20	0,5214	0,6301	0,5672	<b>0,6316</b>	53	0,6943	0,7688	0,7287	<b>0,7855</b>	
	21	0,6377	0,6699	0,6202	<b>0,6944</b>	54	0,5702	<b>0,6184</b>	0,5608	0,5666	
	22	0,5103	0,508	<b>0,5191</b>	0,5108	55	0,5238	<b>0,5485</b>	0,5354	0,5248	
	23	0,5471	0,5877	0,5473	<b>0,5952</b>	56	0,6548	0,6617	0,6275	<b>0,6805</b>	
	24	0,616	0,6358	0,585	<b>0,6594</b>	57	0,6458	<b>0,6638</b>	0,6382	0,6146	
	25	0,488	0,4853	<b>0,5191</b>	0,5177	58	<b>0,7606</b>	0,7137	0,6748	0,7351	
	26	0,4931	0,4864	<b>0,5142</b>	0,5072	59	<b>0,7382</b>	0,7115	0,6733	0,6547	
	27	0,748	0,8083	0,7277	<b>0,8289</b>	60	<b>0,7493</b>	0,7234	0,6854	0,7472	
	28	0,7385	0,8305	0,7112	<b>0,8351</b>	61	<b>0,5537</b>	0,5049	0,5399	0,5127	
	29	0,6363	<b>0,6808</b>	0,6716	0,663	62	0,6219	<b>0,6625</b>	0,5983	0,6011	
	30	0,7717	0,8177	0,7439	<b>0,8252</b>	63	0,7336	<b>0,7465</b>	0,7009	0,7453	
	31	0,5568	<b>0,5786</b>	0,5422	0,5428	64	<b>0,6066</b>	0,6001	0,5831	0,5783	
	32	0,6661	0,6812	0,644	<b>0,7248</b>	65	0,4933	0,4814	<b>0,5129</b>	0,5021	
	33	0,7652	0,8308	0,7312	<b>0,8518</b>	66	0,6191	<b>0,6232</b>	0,5492	0,5475	
	все	0,764	0,805	<b>0,815</b>	0,811						

Таблица 2 - Значения AUC для разных электродов с учетом и без учета сглаживания и требования гладкости решающего правила

Далее был проведен эксперимент, учитывающий критерий селективности признаков. Модель была протестирована разными значениями селективности.






Рисунок 6 – Результаты с учетом селективности

Результат работы комбинированного классификатора

Испытуемый	AUC (исходный)	AUC (Комбинированный классификатор)
1	0.84	0.93
2	0.71	0.85
3	0.82	0.9
4	0.86	0.91

## **Заключение**

Задача классификации возникает в различных сферах человеческой жизни. В частности, при реализации интерфейса мозг-компьютер возникает необходимость распознавать команды головного мозга для определения намерений человека.

Широкое применение данных подход находит в реабилитационной медицине, однако в настоящее время наблюдается тенденция использования ИМК при анализе реакции человека на предъявляемые визуальные стимулы.

В данной работе была рассмотрена и решена задача классификации сигналов энцефалограммы головного мозга, отражающие реакцию эксперта-маммолога на предъявляемые с высокой скоростью снимки маммограмм.

В качестве метода классификации был выбран метод опорных векторов. Повышение качества классификации было достигнуто за счет усовершенствования метода, в частности за счет введения требования гладкости решающего правила, обусловленное наличием отношения порядка на признаках объектов, а также за счет введение квадратично-модульной регуляризации, осуществляющей отбор признаков, что приводит к существенному сокращению признакового пространства.

Также был разработан комбинированный классификатор, основанный на классическом методе опорных векторов и его модификациях, работающий по принципу голосования по большинству, что повышает качество классификации объектов.

Направлением дальнейших научных исследований в этой области является улучшение показателя качества построенного классификатора, основанного на критерии сглаживания, с помощью гибкого механизма варьирования параметров алгоритма.

## Список литературы

1. Wolpaw J.R., McFarland D.J., Neat G.W., Forneris C.A., An EEG-based brain-computer interface for cursor control. *Electroencephalography & Clinical Neurophysiology*. Vol 78(3), Mar 1991, 252—259
2. S. Sanei, J.A. Chambers. *EEG Signal Processing* 2008
3. P. Sajda, E. Pohlmeier, Jun Wang, L. C. Parra, C. Christoforou, J. Dmochowski, B. Hanna, C. Bahlmann, M. K. Singh and Shih-Fu Chang. In a blink of an eye and a switch of a transistor: Cortically coupled computer vision. *Proceedings of the IEEE 98(3)*, pp. 462-478. 2010.
4. J. Touryan, L. Gibson, J. H. Horne and P. Weber. Real-time measurement of face recognition in rapid serial visual presentation. *Frontiers in Psychology*. 2011.
5. Hope C., Sterr A., Elangovan P., Geades N., Windridge D., Young K., Wells K.: High Throughput Screening for Mammography using a Human-Computer Interface with Rapid Serial Visual Presentation(RSVP)
6. Mottl V.V., Dvoenko S.D., Seredin O.S., Krasotkina O.V. Pattern recognition learning taking into account the criterion of smoothness of the decision rule. *Control and Information: proc. of the chair of automation and remote control of TSU*. (2000)
7. Tatarchuk A., Urlov. E, Mottl V., Windridge D.: A support kernel machine for supervised selective combining of diverse pattern-recognition modalities. *MCS*(2010)